

教育背景

香港中文大学, 计算机科学与工程, 博士	2022.8 - 2026.7
• 导师: 徐宏 长聘副教授	
西北工业大学, 计算机科学与技术, 工学学士	2018.9 - 2022.6
• GPA: 93.37/100, 排名: 1/247	
• 国家奖学金两次, 一等奖学金三次, 西北工业大学优秀毕业生	

部分论文发表

预印版

- Kaiwen Chen, [Xin Tan](#), Jingzong Li, Hong Xu. *Libra: Efficient Resource Management for Agentic RL Post-Training*. [Preprint]
- Yicheng Feng, [Xin Tan](#), Yangtao Deng, Yimin Jiang, Yibo Zhu, Hong Xu. *Frontier: Towards Comprehensive and Accurate LLM Inference Simulation*. [Preprint] [Code]

正式出版

- [SIGCOMM'26, CCF-A] [Xin Tan](#), Yicheng Feng, Yu Zhou, Yimin Jiang, Yibo Zhu, Hong Xu. *Dynamic Compute and Network Orchestration for Disaggregated RL*. ACM Special Interest Group on Data Communication. [Preprint]
- [ASPLOS'26, CCF-A] [Xin Tan](#), Yuetao Chen, Yimin Jiang, Xing Chen, Kun Yan, Nan Duan, Yibo Zhu, Daxin Jiang, Hong Xu. *DSV: Exploiting Dynamic Sparsity to Accelerate Large-Scale Video DiT Training*. ACM International Conference on Architectural Support for Programming Languages and Operating Systems. [Publication] [Preprint] [Code]
- [ASPLOS'25, CCF-A] [Xin Tan](#), Yimin Jiang, Yitao Yang, Hong Xu. *Towards End-to-End Optimization of LLM-based Applications with Ayo*. ACM International Conference on Architectural Support for Programming Languages and Operating Systems. [Publication] [Preprint] [Code]
- [ICPP'24, CCF-B] [Xin Tan](#), Jiamin Li, Yitao Yang, Jingzong Li, Hong Xu. *Arlo: Serving Transformer-based Language Models with Dynamic Input Lengths*. ACM International Conference on Parallel Processing. [Publication]
- [ICML'26, CCF-A] Kaihua Liang, [Xin Tan](#), An Zhong, Hong Xu, Marco Canini. *FOCUS: DLLMs Know How to Tame Their Compute Bound*. International Conference on Machine Learning. [Preprint] [Code]
- [IWQoS'26, CCF-B] Kaiwen Chen, [Xin Tan](#), Minchen Yu, Jingzong Li, Hong Xu. *MemShare: Memory Efficient Inference for Large Reasoning Models through KV Cache Reuse*. IEEE/ACM International Symposium on Quality of Service. [Preprint]

实习经历

阿里通义千问 RL Infra 组, 阿里星研发实习生	2026.6-2026.8
• 参与 RL 基础设施的性能优化, 围绕 RL 任务的资源调度、流水线编排与执行效率开展分析和工程优化。	
阶跃星辰 系统组, 研究实习生	2024.9-2026.1
• 参与大规模生成模型训练与后训练系统优化, 方向覆盖 Video DiT 训练加速、RL 后训练编排、集群仿真与资源调度。	
• 在百卡 GPU 集群环境中开展系统瓶颈分析、调度机制设计与工程实现, 相关一作/主导工作发表于 ASPLOS'26 和 SIGCOMM'26。	
微软亚洲研究院 系统与网络研究组, 研究实习生	2021.10-2022.3
• 参与大规模集群非侵入式监控系统开发, 设计并实现 GPU 利用率、网络/NVLink 带宽等指标的分析工具模块, 支持机器学习负载性能评估。	

- 基于数据中心半年工作负载数据分析 AI 任务的资源使用模式与网络需求，撰写内部文档并提出云基础设施与软件栈优化建议。

项目经历

解耦式 RL 后训练系统的计算与网络协同编排 | SIGCOMM'26 一作/主导 2025.5-2026.1

- 针对 RL 后训练中 rollout、训练与权重同步阶段资源需求动态变化的问题，分析生成长尾、KV Cache 占用和阶段性通信模式对端到端吞吐的影响。
- 设计 OrchestrRL 计算调度框架，根据 batch 大小、生成长度分布和剩余请求状态动态切换 TP/EP/AFD 等并行配置，并结合在线请求迁移缓解 straggler。
- 构建 RLSim 仿真与评估框架，并设计 RFabric 可重构光电混合网络；在 64 卡 NVIDIA H800 集群上验证 OrchestrRL 最高提升端到端训练吞吐 1.42 倍，模拟结果显示 RFabric 提升 1.53–2.06 倍性能成本效率。

LLM 推理服务高保真模拟器 Frontier | 预印版/核心贡献 2025.8-2026.5

- 针对现代 LLM 推理服务中 PDD、AFD、复杂并行策略和有状态请求难以被现有模拟器准确刻画的问题，参与设计 Frontier 离散事件仿真器。
- 建模 co-location、PDD、AFD 等部署形态，将 CUDA Graph、speculative decoding、prefix caching 等运行时优化纳入 scheduler-batch-engine 闭环。
- 参与构建计算、通信和内存成本预测模块，覆盖 operator runtime、collective communication、KV Cache 容量和跨 cluster 传输等关键路径；在 16 卡 NVIDIA H800 集群验证中平均吞吐误差低于 4%。

Video DiT 动态稀疏训练加速系统 DSV | ASPLOS'26 一作/主导 2024.9-2025.2

- 针对 Video DiT 在高分辨率长视频训练中的 attention 计算瓶颈，分析动态稀疏性特征，定位全量注意力在多 GPU 训练中的主要开销。
- 设计并实现 DSV 训练加速系统，包括两阶段稀疏性预测、Fused Matmul-Topk/稀疏注意力 Kernel、稀疏感知上下文并行、负载均衡与通信优化。
- 基于 PyTorch FSDP 和 Triton 在 128 卡集群上验证最高 30B 参数 Video DiT 训练，最高提升训练吞吐 3.02 倍，生成质量与全量注意力保持一致。

LLM 应用端到端执行优化系统 Ayo | ASPLOS'25 一作/主导 2024.1-2024.6

- 针对 LLM 应用编排框架中模块边界固化、端到端优化空间受限和请求调度缺乏应用级目标感知等问题，分析多类 LLM 应用工作流的执行瓶颈。
- 设计并实现 Ayo 细粒度编排系统，将应用工作流表示为由任务原语组成的数据流图，支持原语并行、流水线并行和依赖感知调度。
- 基于 Ray 实现系统原型，并在搜索增强生成、检索增强生成等应用中验证效果，最高降低端到端平均延迟 2.09 倍。

变长 Transformer 推理服务优化 Arlo | ICPP'24 一作/主导 2022.10-2023.6

- 针对判别式语言模型面对变长请求时静态编译 padding 开销高、动态编译延迟不稳定的问题，提出混合编译与动态调度方案。
- 基于 Triton Inference Server 和 TensorRT 实现 Arlo，通过长度感知运行时选择和 GPU 资源动态分配优化整体请求延迟。

竞赛获奖

- 国际水下机器人竞赛仿真组冠军，负责人，2020.9
- 龙芯杯大学生系统能力竞赛全国三等奖，负责人，2020.6

专业服务

期刊审稿人

- IEEE Transactions on Network Science and Engineering

Shadow Program Committee

- ACM EuroSys 2026

Artifact Evaluation Committee

- USENIX OSDI/ATC 2025,2024
- USENIX FAST 2025

- ACM CoNEXT 2025
- ACM EuroSys 2025 Spring/Fall

技术能力

- 深度学习/系统开发：PyTorch, Verl, vLLM, Megatron, Triton, CUDA, NCCL, TensorRT
- 编程语言：Python, C++, LaTeX
- 英语：CET-4 619, CET-6 591, IELTS 7.0